

DOCU-INTEL

Sistema de Inteligencia Documental

Informe Técnico y Comercial

Versión 1.0 — Junio 2026

Plataforma interna de OCR, IA y recuperación documental

1. Resumen Ejecutivo

Docu-Intel es un sistema de inteligencia documental que transforma carpetas de documentos en escaneo (presupuestos, pedidos, facturas, albaranes, planos, imágenes, PDFs y Excels) en una base de conocimiento consultable mediante lenguaje natural. Combina OCR multicascada de alta precisión, embeddings semánticos, búsqueda híbrida y un asistente IA local para responder preguntas sobre la documentación empresarial.

Problema que resuelve

Las empresas de construcción y mantenimiento acumulan cientos de gigabytes de documentos por presupuesto: facturas escaneadas, pedidos, planos, correos y hojas de cálculo. Encontrar información específica ("¿cuánto costó la fontanería del hotel X?", "¿dónde está el plano de la planta baja?") requiere horas de búsqueda manual.

Valor para el negocio


- **Ahorro de tiempo:** Búsqueda instantánea en lugar de revisar carpetas manualmente
- **Precisión:** OCR multicascada con preprocesado específico por motor
- **Seguridad:** Aislamiento por presupuesto; precios solo visible por permisos
- **Automatización:** Ingesta 24h, clasificación automática, alertas de calidad
- **Escalabilidad:** Workers GPU separados, procesamiento paralelo
- **Sin dependencia externa:** IA local (sin envío de datos a la nube)

2. Capacidades Principales

2.1 Ingesta Automática de Documentos

Sistema de ingesta 24/7 que monitoriza carpetas compartidas y procesa documentos automáticamente:

- **Watcher 24h:** Detección de archivos nuevos/modificados con polling o eventos nativos
- **Subida web:** Interfaz de arrastrar y soltar para pocos archivos
- **API de integración:** Endpoint dedicado para herramientas externas
- **Importación masiva:** Scripts PowerShell para sincronización incremental de históricos
- **Detección de estabilidad:** Procesa solo cuando el archivo deja de cambiarse



2.2 OCR Multicascada de Alta Precisión

Cadena de motores OCR que selecciona automáticamente el mejor resultado:

Tier	Motor	Caso de uso	Hardware
1	Tesseract 5	PDFs digitales, texto limpio	CPU
2	PaddleOCR 3.5	Escaneos, imágenes, texto manuscrito	GPU
3	PP-Structure	Tablas, layouts complejos	GPU
4	VLM-OCR (Qwen2-VL)	Casos difíciles (fotos, sellos)	GPU

- **Preprocesado específico por motor:** deskew, denoise, binarización adaptativa solo para Tesseract; upscaling y corrección de orientación
- **Score de calidad:** No gana por longitud sino por confianza, densidad alfanumérica y limpieza

- **Logging de degradación:** Cada fallback de cascada se registra y mide

2.3 Extracción de Datos de Negocio

Extracción automática y verificable de campos clave de documentos de negocio:

Tipo documento	Campos extraídos	Persistencia
Presupuesto	Número, cliente, fecha, total, moneda, estado, líneas	budgets, budget_lines
Pedido	Número, proveedor, cliente, fecha, total, referencia a presupuesto	orders, order_lines
Factura	Número, proveedor, base imponible, IVA, total, fecha	invoices
Plano	Escala (1:50, 1:100), cotas, habitaciones con superficies	plans, plan_rooms, plan_dimensions

2.4 Búsqueda Inteligente

Tres modos de búsqueda que se combinan para máxima recall:

- **Texto exacto:** BM25 sobre contenido OCR y metadatos (presupuesto, cliente, referencia)
- **Semántica:** Embeddings BGE-M3 (1024 dims) con pgvector, modo query para consultas asimétricas
- **Híbrida (RRF):** Reciprocal Rank Fusion que fusiona texto + semántico sin calibrar escalas
- **Reranker:** Cross-encoder BGE-reranker-v2-m3 para reordenar los candidatos iniciales

2.5 Chat IA con Fuentes Verificables

Asistente en lenguaje natural que responde preguntas sobre la documentación:

- **15+ tools internas:** Búsqueda documental, presupuestos, pedidos, entidades, planos, duplicados
- **Grounding obligatorio:** Solo responde con fuentes recuperadas; sin inventar datos
- **Respuesta estructurada:** Secciones de Respuesta, Datos, Fuentes, Confianza y Advertencias
- **Multiidioma:** Español, inglés, francés, alemán, italiano, portugués
- **Historial:** Preguntas y respuestas persistidas para referencia

2.6 Planos y Cotas

Módulo especializado en extracción de información de planos técnicos:

- **Escala:** Extracción de ratios 1:50, 1:100, etc.
- **Cotas textuales:** Medidas en m, cm, mm con confianza
- **Habitaciones:** Superficies OCR en m²
- **Anotación manual:** Corrección y edición de escala y habitaciones
- **Detección de símbolos:** YOLOv8 para elementos de plano

2.7 Administración y Gobierno

Panel de administración completo con 6 secciones:

- **Operativa:** Métricas de procesamiento, calidad documental, alertas
- **Estado técnico:** Salud de servicios, workers, disco, colas
- **Integraciones:** API keys, sesiones firmadas, webhooks
- **Usuarios y permisos:** RBAC, roles, tags sensibles, revisión de acceso
- **Calidad:** Revisión OCR, duplicados, cuarentena, reglas de calidad
- **Aprendizaje IA:** Sugerencias de clasificación, patrones aprendidos, bucle de mejora

3. Casos de Uso

3.1 Buscar un Presupuesto por Número

Escenario: Un técnico necesita encontrar el presupuesto 245745 rápidamente.

Flujo: Abre Docu-Intel → Busca "245745" → Ve el presupuesto con cliente, fecha, total y documentos asociados.

Tecnología: Búsqueda exacta por `budget\_code` + BM25 sobre metadatos.

3.2 Consultar Gasto por Proyecto

Escenario: Un director pregunta "¿cuánto nos hemos gastado en el hotel Marina en marzo?"

Flujo: Escribe la pregunta en Chat IA → El sistema ejecuta `aggregate\_business` → Devuelve desglose por tipo de documento con fuentes.

Tecnología: Intent router → tool `aggregate\_business` → SQL exacto sobre entidades extraídas.

3.3 Revisar Documentos de Baja Calidad

Escenario: Un administrador revisa documentos que el OCR no procesó bien.

Flujo: Admin → OCR y calidad → Ve preview, texto extraído, bloques OCR → Aprueba o rechaza con motivo → Reprocesa página específica.

Tecnología: Pipeline de revisión OCR con preview, aprobación/denegación, reprocesado por página.

3.4 Consultar Medidas de un Plano

Escenario: Un instalador necesita saber las dimensiones de la cocina.

Flujo: Chat IA: "¿Cuánto mide la cocina del plano del hotel X?" → Sistema recupera habitaciones del plano → Devuelve ancho, largo, área con fuente.

Tecnología: Extracción de `plan\_rooms` + `plan\_dimensions` + respuesta grounded.


3.5 Integrar con Herramienta Externa

Escenario: Una herramienta de gestión de obra necesita datos de presupuestos.

Flujo: La herramienta crea sesión firmada → Ejecuta tools controladas → Recibe datos con precios solo si tiene permiso.

Tecnología: API `/integrations/v1` con API key, sesiones JWT por presupuesto, redacción automática.

4. Arquitectura General



Flujo de Datos Principal

1. **Ingesta:** Watcher detecta archivo → registra en BD → envía job a Celery
2. **OCR:** Worker renderiza PDF → cascada Tesseract→PaddleOCR→PP-Structure → guarda texto y posiciones
3. **Chunking:** Texto se divide en chunks semánticos con metadatos (tipo, archivo, página)
4. **Embeddings:** Chunks se vectorizan con BGE-M3 (1024 dims) → inserta en pgvector
5. **Clasificación:** Tipo de documento determinado por reglas + learned patterns
6. **Extracción:** Campos clave (nº factura, total, etc.) extraídos por regex y LLM
7. **Búsqueda:** Queries se buscan en texto + vectores → RRF fusiona → reranker reordena
8. **Chat IA:** Pregunta → intent router → tools internas → contexto → LLM local → respuesta grounded

5. Stack Tecnológico


Capa	Tecnología	Versión	Función
Backend API	FastAPI + Uvicorn	0.136 / 0.32	REST API asíncrona
Lenguaje Backend	Python	3.11	Lógica de negocio
Frontend	React + Vite + TypeScript	18.3 / 5.4 / 5.6	SPA moderna
Estilos	Tailwind CSS	3.4	Design system utility-first
State Management	TanStack Query	5.59	Cache y fetching de datos
Tablas	TanStack Table	8.20	Tablas con sorting/filtrado
Base de datos	PostgreSQL + pgvector	16	Metadatos + vectores
Cache / Colas	Redis	7	Broker Celery + cache
Colas	Celery	5.6	Tareas asíncronas
Migraciones	Alembic	1.13	Schema versionado
ORM	SQLAlchemy	2.0	Acceso a BD
Validación	Pydantic	2.10	Schemas y settings
OCR - Tesseract	pytesseract	0.3.13	OCR rápido CPU
OCR - PaddleOCR	PaddleOCR + PaddlePaddle	3.5 / 3.3	OCR preciso GPU
OCR - PP-Structure	PaddleOCR (PP-Structure)	3.5	Tablas y layout
Visión por computadora	OpenCV	4.10	Preprocesado de imágenes
PDF parsing	PyMuPDF + pdfplumber	1.24 / 0.11	Extracción de texto PDF
Excel	openpyxl + pandas	3.1 / 2.2	Lectura de spreadsheets
Detección objetos	YOLOv8 (ultralytics)	8.0+	Símbolos de plano
Embeddings	sentence-transformers	3.0+	BGE-M3 (1024 dims)
Reranker	BGE-reranker-v2-m3	—	Reordenación cross-encoder
LLM Local	Qwen2.5-32B via LM Studio	—	Generación de respuestas
Geometría	Shapely + ezdxf	2.0 / 1.4	Geometría y DXF

Monitorización	Sentry / GlitchTip	2.19	Error tracking
Métricas	Prometheus	0.20+	/metrics endpoint
Containerización	Docker + Docker Compose	—	Despliegue
GPU	NVIDIA RTX 4070 × 2	CUDA	OCR + embeddings + LLM
Testing	pytest + Vitest + Playwright	8.3 / 2.1 / —	Unit + E2E
CI/CD	GitHub Actions	—	CI pipeline

6. Pipeline OCR y Preprocesado

6.1 Cascada de Motores

El sistema implementa una cascada de 4 motores OCR que selecciona automáticamente el mejor resultado usando un score de calidad:



6.2 Score de Calidad

El motor "ganador" NO se decide por longitud (que favorece ruido) sino por un score compuesto:

$$\text{quality(result)} = \text{confidence} \times 0.5 + \text{density} \times 0.3 + \text{length_factor} \times 0.2$$

Donde:

- **confidence**: Confianza media del motor OCR (0-1)

- **density**: Proporción de caracteres alfanuméricos y espacios (penaliza basura simbólica)
- **length_factor**: $\min(\text{len}(\text{text})/500, 1.0)$ — satura, no premia infinito

6.3 Preprocesado de Imágenes

Operación	Para Tesseract	Para PaddleOCR
Conversión a escala de grises	Sí	Opcional
Reducción de ruido (denoise)	Sí (bilateral)	Sí (suave)
Deskew (corrección inclinación)	Sí	Sí
Binarización adaptativa	Sí (mejora显著)	NO (perjudica)
Upscaling (si DPI bajo)	Sí (×2 CUBIC)	Sí (×2 CUBIC)
Corrección orientación (OSD)	Sí (90°/180°/270°)	Sí

6.4 Workers GPU

Dos workers GPU independientes con RTX 4070 dedicada cada uno:

- **worker-heavy-gpu-0**: CUDA_VISIBLE_DEVICES=0, concurrencia 1
- **worker-heavy-gpu-1**: CUDA_VISIBLE_DEVICES=1, concurrencia 1
- **worker-heavy (CPU fallback)**: Sin GPU, para cuando las GPUs no están disponibles

7. IA y Recuperación (RAG)

7.1 Pipeline de Embeddings



7.2 Búsqueda Híbrida con RRF

La fusión de resultados textuales y semánticos usa Reciprocal Rank Fusion (RRF), robusto y sin necesidad de calibrar escalas:

RRF.score(d) = $\sum 1/(k + \text{rank}_i + 1)$ para cada lista de resultados

Donde k=60 (constante estándar). Cada fuente (texto, semántico) aporta su ranking, no su score absoluto.

Resultado: Un documento que solo aparece en semántica con alta relevancia puede superar a un match léxico débil.

7.3 Agent IA y Tools


El agente IA decide qué herramientas ejecutar basándose en la pregunta del usuario:

Tool	Función	Ejemplo de uso
------	---------	----------------

hybrid_search	Búsqueda textual+semántica	"¿Qué dice sobre fontanería?"
get_budget_by_number	Presupuesto por número exacto	"Dame el presupuesto 245745"
aggregate_business	Agregaciones de negocio	"¿Cuánto hemos gastado en X?"
get_orders_by_number	Pedido por número	"¿Tiene pedido el presupuesto X?"
get_plan_dimensions	Medidas de habitaciones	"¿Cuánto mide la cocina?"
find_duplicates	Duplicados de documentos	"¿Hay documentos duplicados?"
list_documents_needing_review	Docs de baja calidad	"¿Qué documentos necesitan revisión?"
propose_*	Sugerencias de mejora	Agente externo propone correcciones

7.4 Learning Loop (Bucle de Mejora)

El sistema aprende de las correcciones humanas y las propuestas del agente externo:



8. Seguridad y Permisos

8.1 Modelo de Roles (RBAC)

Rol	Permisos	Restricciones
admin	Total: admin, documentos, jobs, configuración	Ninguna
gestor	Documentos, planos, búsqueda, revisión OCR	Sin acceso a admin/sistema
operario	Documentos, búsqueda, chat IA	Sin precios, sin planos, sin admin

8.2 Aislamiento por Presupuesto

Regla crítica: El aislamiento principal es por `budget_scope_id` , no por usuario o cadena. Una sesión firmada limita todas las consultas al presupuesto específico.

- **API keys:** Identifican al cliente (herramienta externa)
- **Sesiones firmadas (JWT):** Vinculan a un presupuesto específico con caducidad
- **Permisos por scope:** `can_query` (consultar) y `can_see_amounts` (ver precios)
- **Políticas por técnico:** `operario_minimo` (sin precios) vs `precios_autorizados`

8.3 Redacción de Precios

Cuando un técnico no tiene permiso para ver importes:

- Los campos de precio se reemplazan por `[IMPORTE OCULTO]`
- La redacción se aplica **antes** de entregar contexto a la IA externa
- La IA no recibe precios, márgenes ni condiciones comerciales

8.4 Auditoría

- Cada acción queda registrada en `audit_logs` con usuario, acción, entidad y timestamp
- Filtros por acción, entidad y usuario en `/admin/audit-logs`
- Simulador de permisos: `/admin/access-explain` para verificar por qué un usuario puede o no ver un documento

8.5 Webhooks Firmados

Las notificaciones a herramientas externas van firmadas con HMAC-SHA256:

- `X-DocuIntel-Signature`: Firma HMAC del payload
- Eventos: `document.processed`, `document.failed`, `document.needs_review`, `classification.low_confidence`, `entity.new_pattern_detected`

9. Infraestructura y Despliegue

9.1 Servicios Docker

Servicio	Función	Puerto	Notas
backend	API FastAPI	8000	Healthcheck cada 30s
frontend	React (nginx)	5173/5174	Proxy a backend
postgres	PostgreSQL 16 + pgvector	5432 (interno)	No expuesto en prod
redis	Redis 7	6379 (interno)	Broker + cache
worker-fast	Celery: texto, embeddings	—	Concurrencia 2
worker-heavy	Celery: OCR CPU	—	Concurrencia 1
worker-heavy-gpu-0	Celery: OCR GPU	—	RTX 4070 #0
worker-heavy-gpu-1	Celery: OCR GPU	—	RTX 4070 #1
worker-maintenance	Celery: limpieza	—	Aprendizaje, webhooks
watcher	Monitorización 24h	—	Polling o nativo
scheduler	Celery Beat	—	Tareas periódicas
migrate	Alembic migrations	—	One-shot sidecar
pgadmin	Administración BD	5050	Profile: tools
glitchtip	Error tracking	8001	Profile: monitoring

9.2 Hardware Recomendado

Componente	Mínimo	Recomendado
CPU	4 cores	8+ cores (AMD/Intel modern)
RAM	16 GB	32+ GB
GPU	Sin GPU (CPU fallback)	2× RTX 4070 (12GB VRAM c/u)
Disco	100 GB SSD	500+ GB NVMe (para docs)

Red	1 Gbps	1+ Gbps (para ingesta masiva)
-----	--------	-------------------------------

9.3 Backup y Restore

- **PostgreSQL:** Backup completo de la base de datos
- **Files:** `/data/files` (documentos originales)
- **Redis:** Snapshot RDB (colas Celery, cache)
- **Scripts:** PowerShell con verificación de integridad
- **Restore probado:** Entorno separado para validar backups

9.4 CI/CD

- **GitHub Actions:** Verificación de migraciones Alembic, tests backend, tests frontend, build Vite
- **Linting:** ESLint (frontend) + ruff/flake8 (backend)
- **Type checking:** TypeScript strict mode

10. Base de Datos

10.1 Modelo Principal



10.2 pgvector para Embeddings

Tabla: document_chunks

Columna: embedding vector(1024)

Modelo: BGE-M3 multilingüe (sentence-transformers)

Índice: IVFFlat o HNSW para búsqueda eficiente

Búsqueda: Cosine similarity con <=> operator

10.3 Tablas Principales

Tabla	Registros típicos	Función
documents	10.000-100.000	Documentos ingeridos
document_chunks	100.000-1.000.000	Chunks con embeddings
pages	50.000-500.000	Páginas de PDFs

ocr_blocks	200.000-2.000.000	Bloques OCR con bbox
budgets	500-5.000	Presupuestos extraídos
orders	200-2.000	Pedidos extraídos
plans	100-1.000	Planos con cotas
audit_logs	100.000+	Registro de acciones
ai_questions	1.000-10.000	Historial de chat

11. Roadmap y Fases

Fase	Estado	Funcionalidades
Fase 1	Completada	Ingesta, OCR básico, chunking, embeddings, búsqueda textual
Fase 2	Completada	Extracción presupuestos/pedidos, entidades, dashboard
Fase 3	Completada	Embeddings reales, búsqueda semántica/híbrida, chat IA con tools
Fase 4	Completada	Planos: escala, cotas, habitaciones, anotación manual
Fase 5	Operativa	Alertas, auditoría, reprocesado, integraciones, aprendizaje IA
Fase 6	Planificada	Extracción geométrica avanzada, VLM-OCR Tier 4, planos complejos

Mejoras en Curso (Backlog)

- **O1:** Conectar preprocesado real (hoy no se aplica en ninguno de los 3 motores)
- **O3:** Score de calidad compuesto en cascada (no ganar por longitud)
- **A1:** Fix query/passage mode en embeddings (recall degradado)
- **A2:** Fusión híbrida con RRF en vez de escalas fijas
- **PL1-PL6:** Planos: usar escala, geometría, parsing robusto de medidas
- **F1-F2:** Frontend: code-splitting + gating de rutas por rol

12. Métricas y Calidad

12.1 Estados de Calidad Documental

Estado	Significado	Acción
<code>processed_ok</code>	OCR exitoso, campos extraídos	Ninguna
<code>processed_low_quality</code>	OCR con baja confianza	Revisión recomendada
<code>processed_missing_fields</code>	Faltan campos clave	Revisión de extracción
<code>needs_human_review</code>	Requiere intervención humana	Revisión obligatoria
<code>failed</code>	Error en procesamiento	Reprocesar

12.2 Dashboard de Métricas

- **/admin/processing-metrics:** Documentos por estado/tipo, jobs por estado
- **/admin/operations/overview:** GB procesados, ETA de cola, calidad documental
- **/admin/quality/summary:** Resumen de calidad con reglas configurables
- **/admin/production/readiness:** DB, Redis, workers, watcher, directorios

12.3 Alertas Automáticas

- Presupuestos aceptados sin pedido
- Pedidos sin presupuesto asociado
- Documentos con OCR de baja calidad
- Disco bajo en almacenamiento
- Planos sin escala válida
- Jobs fallidos en Cola Celery
- Backpressure en procesamiento

13. Conclusión

Docu-Intel es una plataforma completa de inteligencia documental que combina:

- **OCR industrial:** 4 motores en cascada con preprocesado específico
- **IA local:** Sin dependencia de servicios externos, total control de datos
- **Seguridad:** Aislamiento por presupuesto, RBAC, auditoría completa
- **Escalabilidad:** Workers GPU separados, procesamiento paralelo
- **Gobierno:** Calidad documental, aprendizaje automático, alertas

El sistema está en producción activa, procesando documentos de presupuestos, pedidos, facturas y planos con alta precisión. La arquitectura modular permite escalar desde un servidor hasta un clúster con múltiples GPUs según la carga de trabajo.